EVOLVE ACADEMY · MÁSTER EN DATA SCIENCE & IA

Predicción de Cancelación de Reservas Hoteleras

Un modelo de Machine Learning al servicio de Revenue Management

Adrián Potenciano Vila

Caso práctico · Hotel Booking Demand Dataset (Antonio, Almeida & Nunes, 2019)

El problema de negocio

Una cadena hotelera con dos propiedades en Portugal necesita anticipar, en el momento de la reserva, qué clientes tienen alta probabilidad de cancelar — para activar acciones preventivas de Revenue Management.



Ofrecer upgrades con descuento a clientes de bajo riesgo, para fidelizar



Solicitar depósito no reembolsable de forma selectiva en reservas de alto riesgo



Ajustar la política de overbooking para minimizar habitaciones vacías de última hora

El coste NO es simétrico

Falso Negativo

Cliente cancela y no se detecta → habitación vacía a precio de coste.

Falso Positivo

Se predice cancelación y no ocurre → acción preventiva innecesaria, cliente fiel molesto.

El modelo debe equilibrar ambos errores según su coste real.

El dataset y las reglas del juego

119.210

reservas (tras limpieza)

2

hoteles · City & Resort

Jul 2015 – Ago 2017

periodo cubierto

37,1%

tasa de cancelación



Data leakage: excluido sin excepción

reservation_status y **reservation_status_date**: revelan literalmente el resultado.

assigned_room_type: se define cerca del check-in, después del momento de la reserva → fuga temporal.



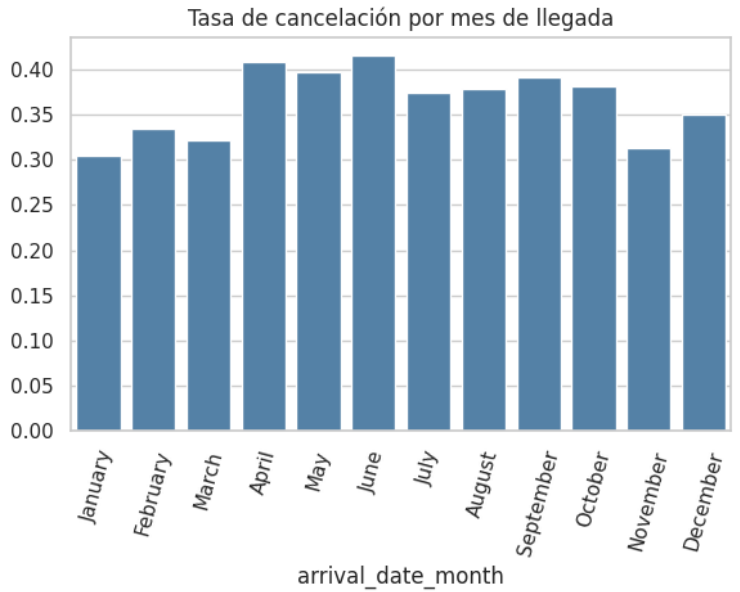
Limpieza aplicada

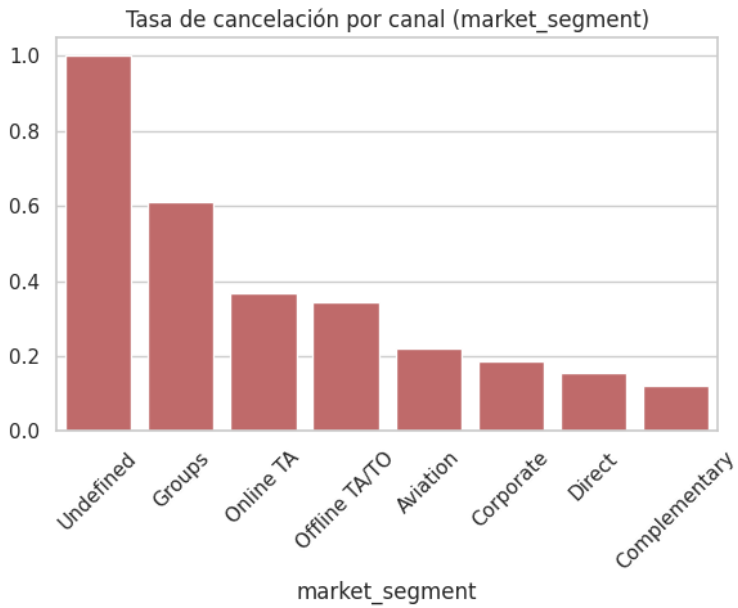
- children nulo → 0
- country nulo → "Unknown"; 177 países agrupados en Top 10 + Other
- 1 registro con adr negativo → corregido a 0
- 180 reservas sin huéspedes → eliminadas
- company (94% nulo) → excluida

Insight de negocio #1

¿Quién cancela más? Hotel y canal de captación



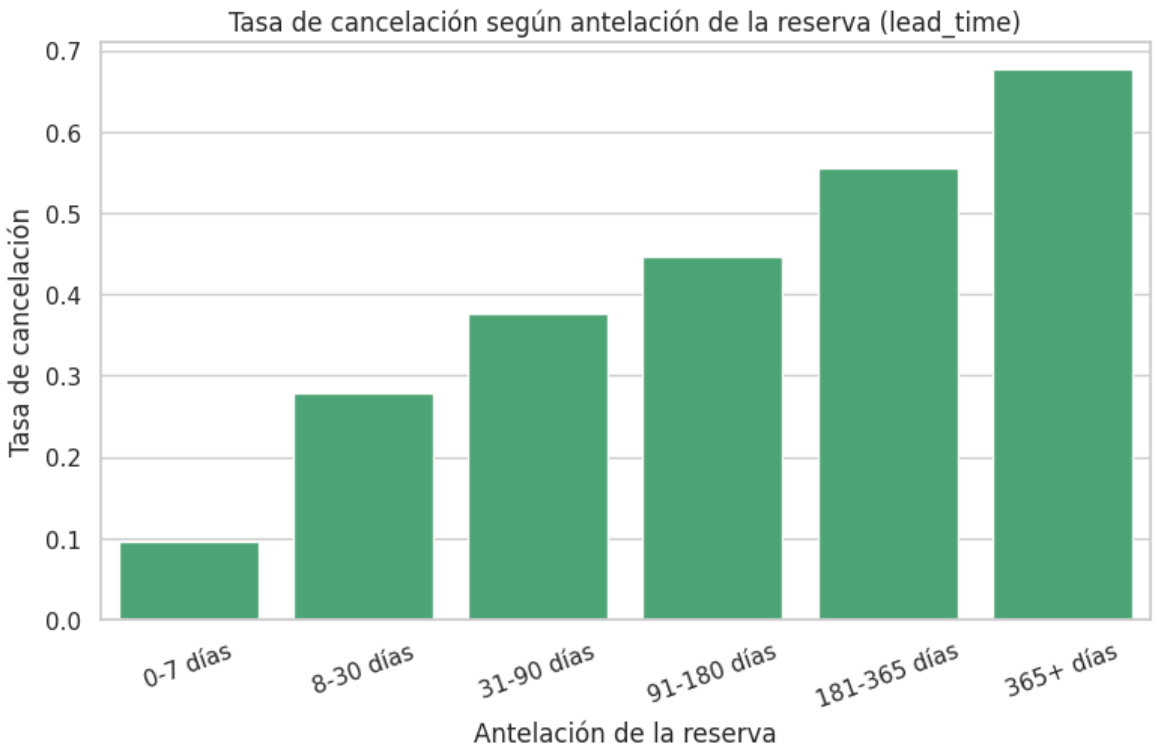




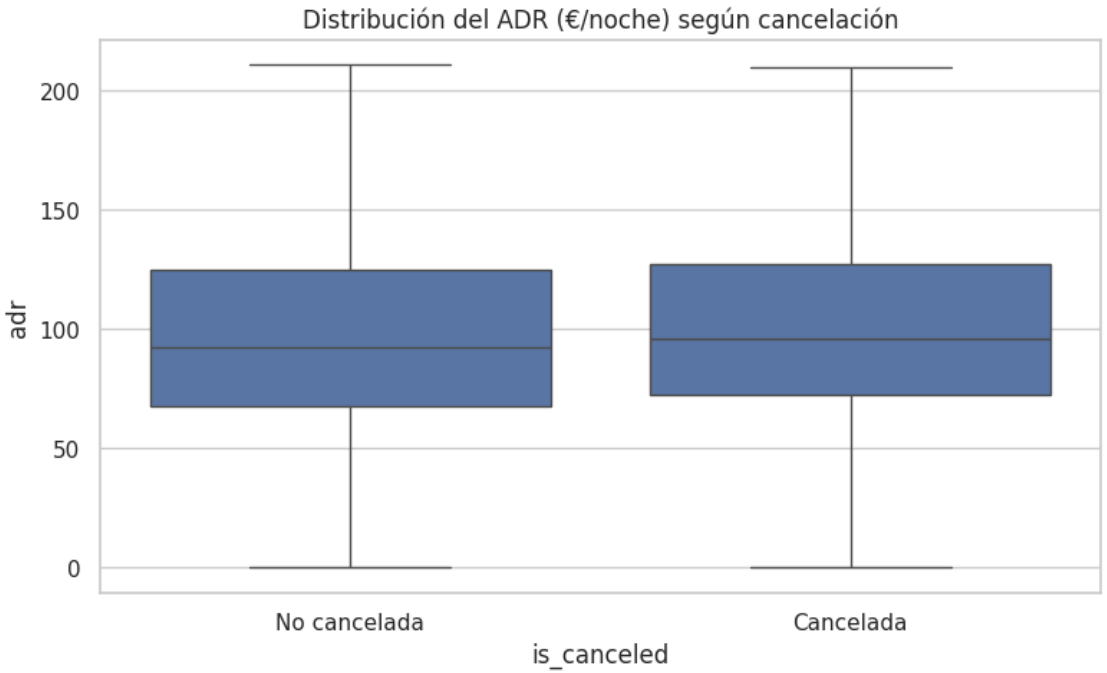
Acción de negocio: el City Hotel cancela un 42% frente al 28% del Resort, y los canales Groups (61%) y Online TA (37%) cancelan mucho más que Direct (15%). Prioriza el scoring y el depósito no reembolsable en el City Hotel captado vía agencias/grupos.

Insight de negocio #2 y #3

Antelación de reserva y precio (ADR)



Lead time: de 9,6% (última hora) a 67,7% (365+ días) de cancelación. Señal muy fuerte.



ADR: canceladas 105,0€ vs. no canceladas 100,2€ de media — el precio solo no discrimina bien.

Feature engineering

8 variables nuevas construidas a partir de las existentes, cada una con justificación de negocio.



customer_risk_ratio

% histórico de cancelaciones del propio cliente — comportamiento repetido predice riesgo futuro.



booked_via_agent

Reservas vía agente suelen ser más volátiles que las directas del cliente final.



is_high_season

Julio/agosto concentran reservas especulativas con más probabilidad de cancelarse.



total_nights / total_guests

Estancias más largas y grupos implican mayor compromiso logístico y económico.



is_family

Viajes familiares se planifican con antelación y son menos flexibles (vacaciones escolares).



country_grouped

Top 10 países + "Other": evita sobreajuste por cardinalidad en el resto de nacionalidades.

Partición temporal, no aleatoria

Un split aleatorio filtraría información del futuro hacia el pasado. Entrenamos con historia y evaluamos sobre reservas futuras — el escenario real de producción.



103.338

reservas de train

36,7% cancelación

15.872

reservas de test

39,3% cancelación

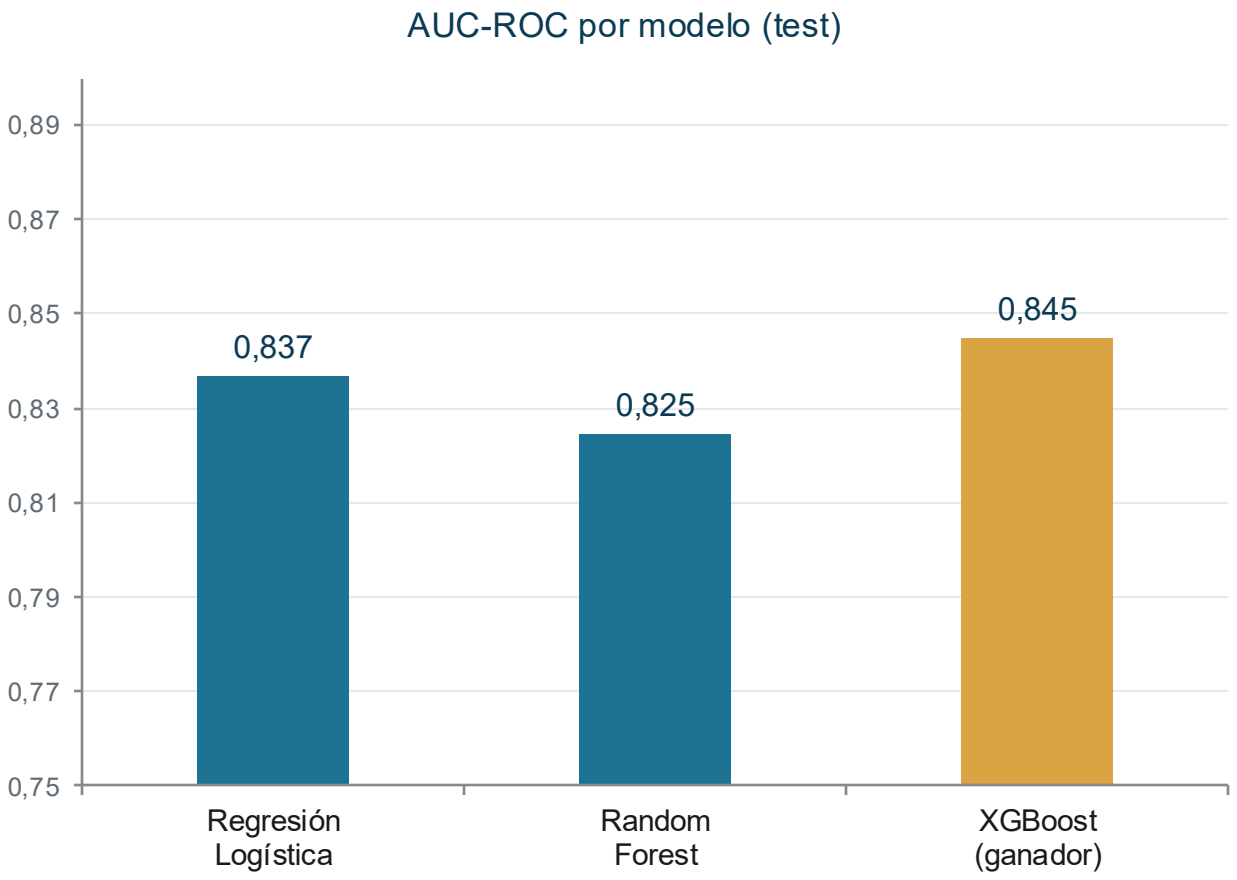
82

features tras encoding

9 categóricas + 23 numéricas

Tres modelos, un ganador claro

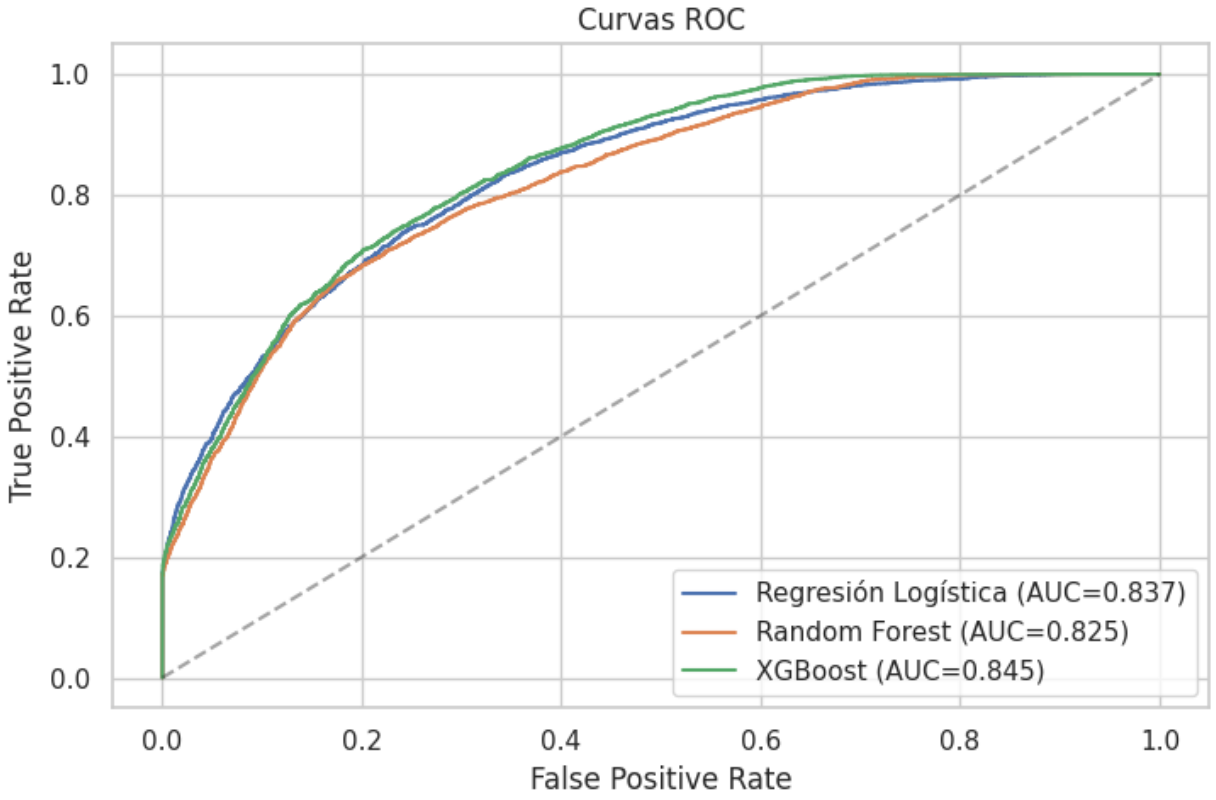
Baseline interpretable → modelos más potentes, solo si superan el baseline. Desbalanceo gestionado con class_weight / scale_pos_weight.

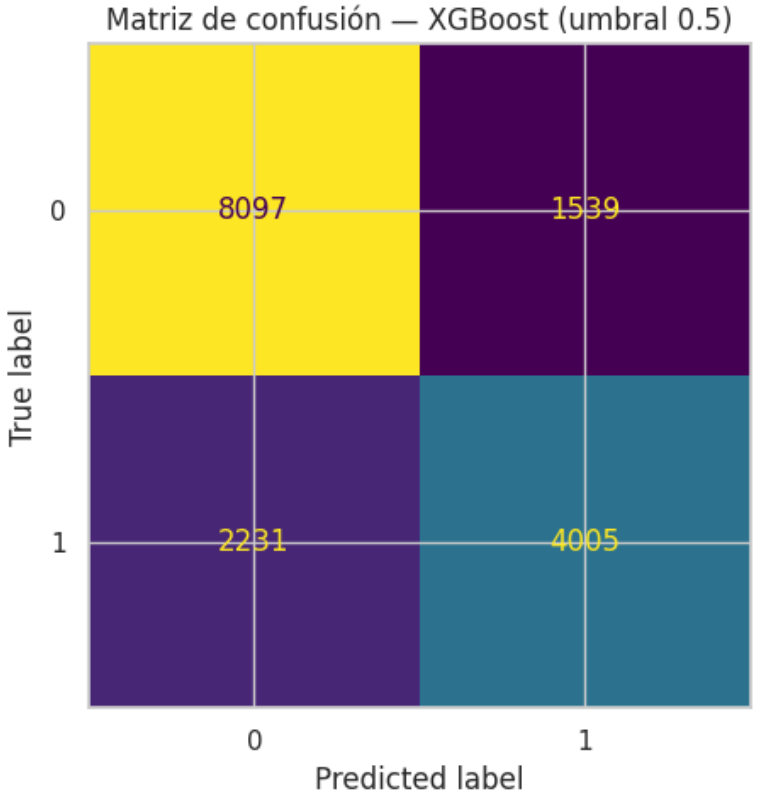


Modelo	AUC-ROC	F1	Precision	Recall
Reg. Logística (baseline)	0.837	0.696	0.667	0.728
Random Forest (tuned)	0.825	0.662	0.735	0.601
XGBoost (Optuna) — ganador	**0.845**	**0.680**	**0.722**	**0.642**

XGBoost optimizado con Optuna gana en AUC-ROC — la métrica más robusta frente al desbalanceo y que no depende de un umbral fijo. A partir de aquí trabajamos con este modelo.

XGBoost: curva ROC y matriz de confusión





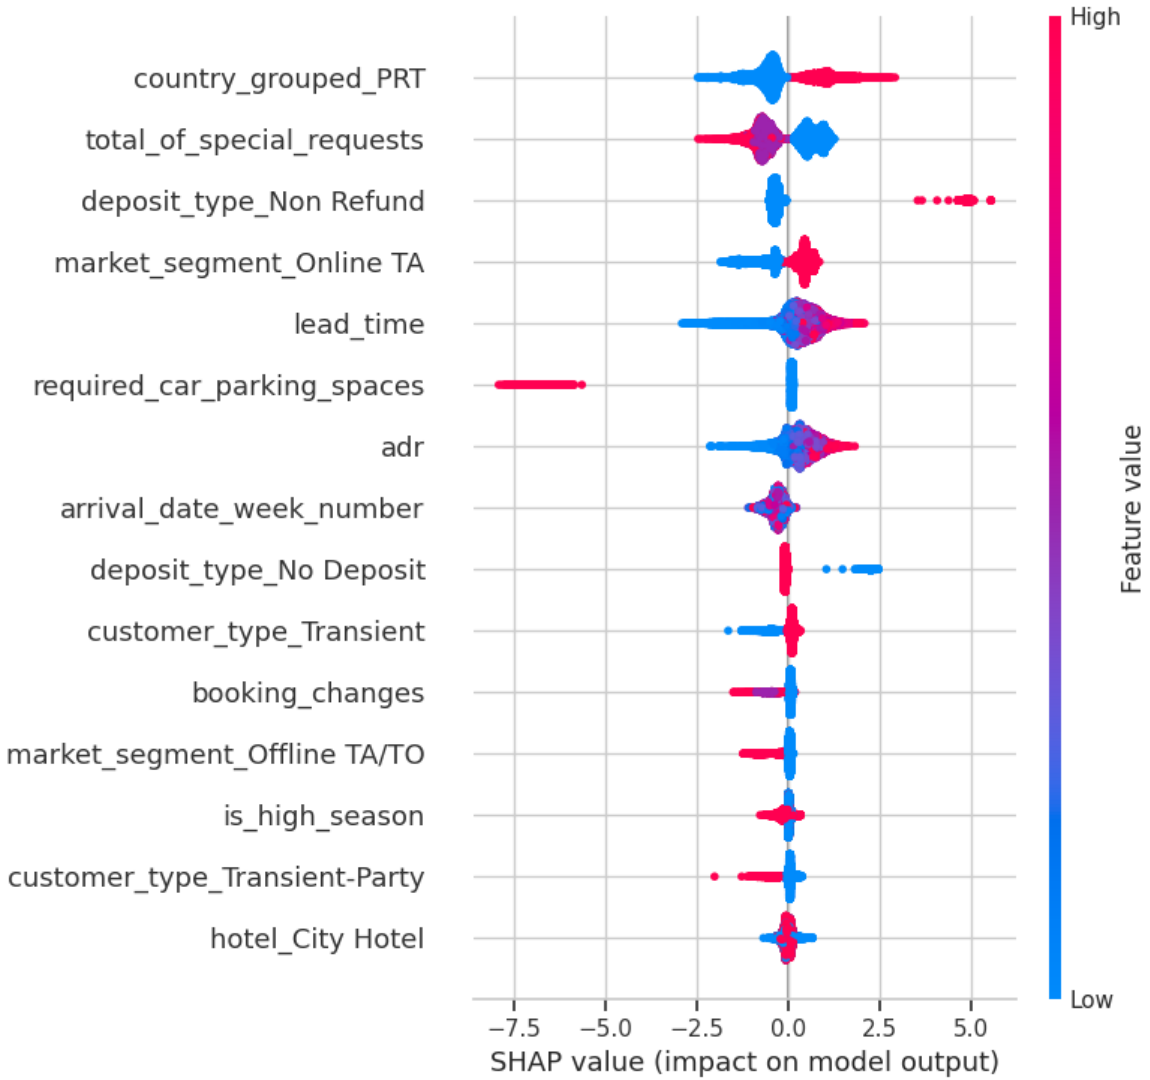
Hiperparámetros óptimos (Optuna): n_estimators=225, max_depth=8, learning_rate=0.145, subsample=0.84, colsample_bytree=0.66, scale_pos_weight=1.72

¿Qué variables pesan más?

Interpretabilidad con SHAP

- country_grouped_PRT (cliente portugués)
- total_of_special_requests (a menos, más riesgo)
- deposit_type_Non Refund
- market_segment_Online TA
- lead_time
- required_car_parking_spaces (protector)
- adr

Top-7 variables por importancia media (|SHAP|)

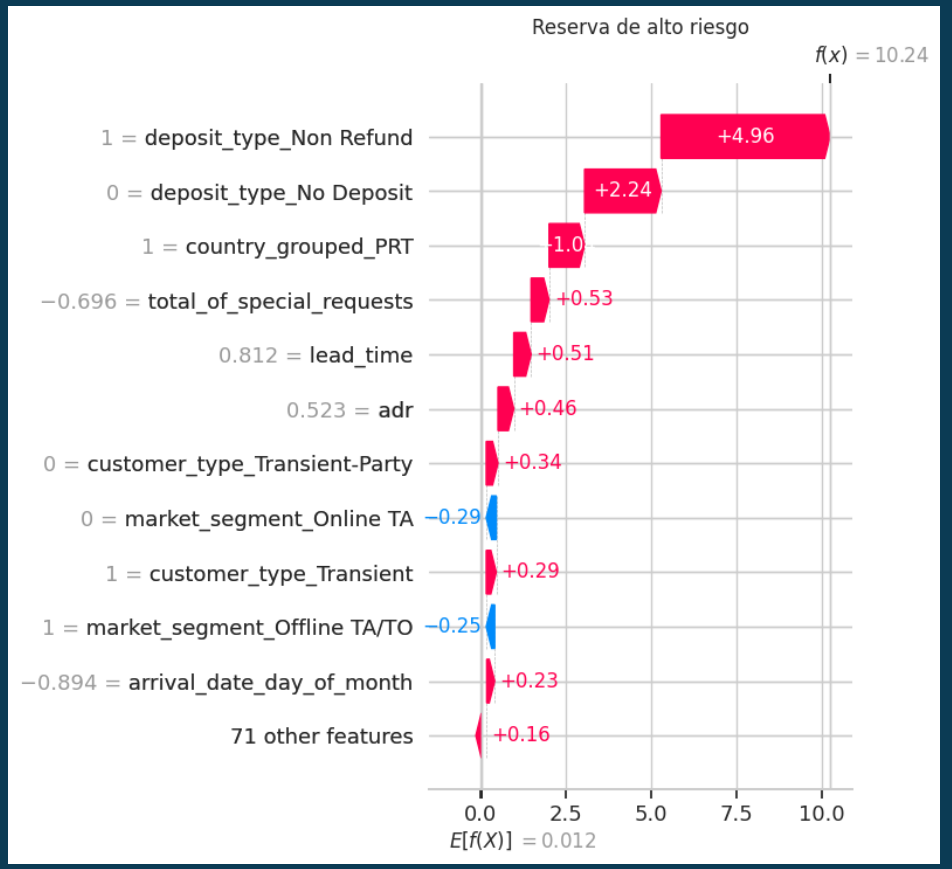


El hallazgo más interesante

Un depósito **“Non Refund”** es uno de los mayores impulsores hacia **MAYOR** probabilidad de cancelación — no menor.

En este dataset, las reservas “Non Refund” se corresponden más con bloqueos masivos de agencias/mayoristas que después se cancelan en bloque, que con clientes individuales comprometidos con una tarifa no reembolsable.

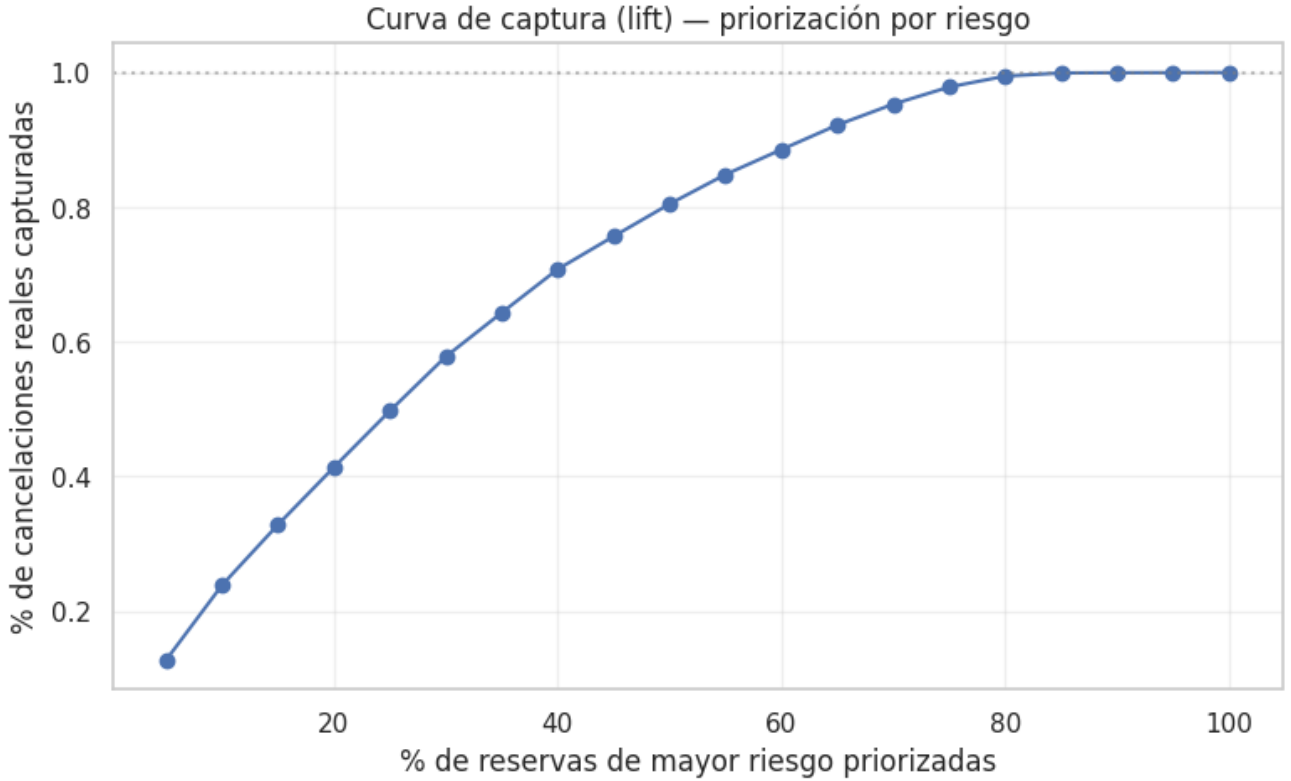
Por qué importa: una regla ingenua (“depósito no reembolsable = cliente comprometido = bajo riesgo”) sería directamente errónea con estos datos. La interpretabilidad evita construir intuiciones de negocio equivocadas.



SHAP waterfall — reserva de alto riesgo real (f(x)=10.24)

De un umbral fijo a una lista de prioridades

El umbral matemáticamente óptimo por coste marca casi todo como riesgo → inviable operativamente. Proponemos priorizar por percentil de score.



20% de las reservas priorizadas por riesgo **capturan el 41% de las cancelaciones reales**

30% de las reservas priorizadas por riesgo **capturan el 58% de las cancelaciones reales**

50% de las reservas priorizadas por riesgo **capturan el 81% de las cancelaciones reales**

El equipo puede dimensionar su lista de trabajo según su capacidad operativa real, en lugar de un corte de probabilidad único y rígido.

Propuesta de negocio

Cómo usar el modelo en la operativa diaria de Revenue Management.



Top 20-30% por score

Contacto proactivo para confirmar la estancia. Si es reserva directa: valorar depósito. Si viene de agencia/grupo: renegociar políticas de bloqueo y cancelación en origen.



Franja de riesgo medio

Incentivar peticiones especiales y upgrades con descuento — aumentan el compromiso del cliente y reducen la probabilidad real de cancelación.



Overbooking estacional

Ajustar la política de overbooking del City Hotel en temporada alta (jul-ago), donde la tasa de cancelación es consistentemente mayor.

Próximos pasos

1. Recalibrar el coste de FN/FP con cifras reales de Revenue Management, no una aproximación basada en ADR medio.

2. Monitorizar el modelo en producción y reentrenar periódicamente (drift estacional y de canal de distribución).

3. Incorporar variables externas: precios de la competencia, eventos locales, climatología.

4. Evaluar un modelo específico por hotel — el comportamiento de cancelación difiere notablemente entre City y Resort.



Gracias

Predicción de Cancelación de Reservas Hoteleras · Preguntas y discusión